

Caso de estudio: Reconstrucción del campo de flujo en una cavidad cuadrada*

Dr. Ing. Benjamin A. TOURN - Esp. Ing. Braian DESIA

3er bimestre 2026

TP1 - Pipeline básico para construcción de modelos PINN

Datasets de puntos de colocación

Los puntos de colocación para entrenar un modelo PINN se definen en relación con los términos que se pretenden incluir en la función de pérdida del modelo. Para el caso de la cavidad cuadrada, existirán puntos sobre los que se deberán computar los residuos r_{pde} y r_{bc} de las PDE de gobierno y de las condiciones de borde, respectivamente. De esta manera, el dataset de entrenamiento queda conformado como una colección de sub-conjuntos de puntos de colocación, cada uno relacionado con el término correspondiente en la función de pérdida.

Realizar las siguientes actividades:

1. Definir los sub-conjuntos de puntos de colocación según el tipo de residuo que deberían incluir en la función de pérdida, y teniendo en cuenta la configuración geométrica del problema. Utilizar $N_{pde} = 1000$ y $N_{bc} = 100$. Implementar estrategia de muestreo tipo aleatorio.
2. Graficar los puntos de colocación. Emplear un color distinto según el subconjunto al que pertenecen.
3. Inclusión de datos rotulados: considere la existencia de $N_{data} = 10$ puntos (x, y) en el dominio (no constituyen específicamente “puntos de colocación”) sobre los que se cuenta con mediciones de presión p y velocidades (u, v) , distribuidos de forma aleatoria. Construya el dataset correspondiente, incluyendo los *labels* (para ello, utilice los datos de presión y velocidad suministrados). ¿Qué le sugiere la estructura de datos de este dataset complementario respecto a los sub-conjuntos de puntos de colocación, en relación con los *labels*?
4. Para pensar: el sub-conjunto de los puntos de colocación correspondientes a la PDE de la ecuación de gobierno, ¿debería o no contener puntos definidos sobre las fronteras físicas del dominio?

Implementación de esquema *vanilla* PINN

La implementación básica de un esquema *vanilla* PINN para realizar el cómputo “directo” de las variables dependientes en estudio (en este caso, la presión p y velocidades u y v) incluye como mínimo los siguientes aspectos:

*Basado en la contribución del Dr. Khemraj Shukla de Brown University para curso NVIDIA Modulus

- Construcción de los datasets de entrenamiento a partir de los subconjuntos de puntos de colocación (aspecto abordado en el apartado anterior).
- Definición de la arquitectura de la red neuronal FC: número de variables de entrada (depende de las variables independientes el problema) y de salida (depende de las variables dependientes a modelar), número de capas (profundidad), ancho (número de neuronas por capa) y funciones de activación.
- Desarrollo de las rutinas para calcular los residuos, que implica el uso del esquema de autodiferenciación.
- Elección del optimizador y de los hiperparámetros correspondientes (*learning rate*, *weight decay*, etc).
- Inicialización de los parámetros entrenables (usualmente mediante estrategias de Xavier o He).
- Definición de otros hiperparámetros (cantidad de *epochs*, pesos de los términos de la función de pérdida, etc).
- Proceso de entrenamiento (*loop* sobre *epochs*): en cada *epoch* se debe computar la función de pérdida total como suma ponderada de las contribuciones de la pérdida para cada sub-conjunto del dataset de entrenamiento.
- Impresión en pantalla de los *logs* de entrenamiento cada *n epochs*.
- Elaboración de los gráficos de evolución de las funciones de pérdida de los residuos y la función de pérdida total al finalizar el entrenamiento.

Realizar las siguientes actividades:

1. Implementar una rutina que incluya los pasos enumerados previamente. Tomar como referencia las implementaciones provistas por la cátedra (ver *notebooks* de Colab). Prestar especial atención al cómputo de las derivadas de la presión p y velocidades u y v en función de las variables independientes, y a la construcción de los residuos correspondientes.
2. Resolver el sistema de ecuaciones del enunciado mediante PINN, sin emplear datos rotulados. ¿Considera suficiente la cantidad de puntos de colocación N_{pde} y N_{bc} definida previamente?
3. Calcular la norma-2 del error entre los valores de presión $\hat{p}$ y velocidades $(\hat{u}, \hat{v})$ que predice el modelo y sus correspondientes valores *ground-truth*. Para ello, computar los campos de presión y velocidad en la misma grilla de puntos que la empleada en la solución de referencia.
4. Graficar el error absoluto entre los valores de presión $\hat{p}$ y velocidades $(\hat{u}, \hat{v})$ que predice el modelo y sus correspondientes valores medidos (utilizando la misma grilla que en el punto anterior).
5. Mostrar los perfiles de velocidad y presión computados por el modelo en comparación con los perfiles *ground-truth*, sobre las coordenadas $x = 0,5$ y $y = 0,5$.
6. En base al grado de convergencia obtenido durante el entrenamiento y los gráficos de error ¿Considera que el modelo desarrollado es suficientemente “bueno” para predecir los campos de presión y velocidad? ¿Qué fallas observa? ¿Qué aspectos positivos destaca? ¿Considera que los hiperparámetros que definió son adecuados? ¿Puede mejorarse el desempeño del modelo? En caso afirmativo ¿Qué acciones de mejoras se podrían implementar?