

Caso de estudio: Reconstrucción del campo de flujo en una cavidad cuadrada*

Dr. Ing. Benjamin A. TOURN - Esp. Ing. Braian DESIA

3er bimestre 2026

TP3 - Diseño experimental e identificación de Re

Hasta el momento, se resolvió el problema directo para $Re^* = 100$ conocido. En este TP, se propone que Re sea la incógnita, y que sea determinada mediante una formulación PINN inversa utilizando para ello únicamente datos de velocidad. Asumimos $\sigma_u = \sigma_v = 1\%$ del valor máximo del campo correspondiente en Ω .

Actividades a realizar:

- **Sensibilidad a priori (sin datos rotulados):** A partir del modelo PINN entrenado en el TP 1 (entrenado en modo púramente físico, sin datos rotulados) con $Re^* = 100$, deberán entrenar una segunda instancia idéntica con $Re + \Delta Re$, con $\Delta Re = 5$. Utilizando ambas instancias, deberán calcular por diferencias finitas, en una grilla de 300×300 , el mapa de sensibilidad $\varepsilon_{Re}(x, y)$ en todo el dominio, como mapa de calor, dado por:

$$\varepsilon_{Re}(x, y) = \sqrt{\left(\frac{1}{\sigma_u} \frac{\Delta u}{\Delta Re}\right)^2 + \left(\frac{1}{\sigma_v} \frac{\Delta v}{\Delta Re}\right)^2}$$

¿Dónde se concentra la sensibilidad? ¿Coincide con alguna estructura física reconocible del flujo (capa de corte, núcleo del vórtice, zonas de recirculación en las esquinas)?

- **Tres configuraciones de sensores, mismo tamaño, distinta ubicación.** Fijar una única grilla de $N_{data} = 9$ puntos (3×3), de tamaño $0,25 \times 0,25$, y ubicarla en tres posiciones distintas dentro de Ω :
 - a) Centrada en la zona de **máxima** ε_{Re} promedio, según el mapa del ítem anterior.
 - b) Centrada en Ω .
 - c) Centrada en una zona de **mínima** ε_{Re} (por ejemplo, una esquina de recirculación).

Para cada configuración, calcular el valor **predicho**

$$\mathcal{I}(Re) = \sum_{i=1}^9 \varepsilon_{Re}(x_i, y_i)^2,$$

y ordenar las tres configuraciones de mejor a peor identificabilidad esperada —**antes de entrenar ningún modelo inverso**.

*Basado en la contribución del Dr. Khemraj Shukla de Brown University para curso NVIDIA Modulus

- **Entrenamiento inverso.** Con datasets de colocación contruidos mediante LHS ($N_{\text{pde}} = 10,000$, $N_{\text{bc}} = 1,000$, igual que en el TP anterior), entrenar el modelo inverso para las 3 configuraciones de sensores definidas en el ítem anterior, considerando en cada caso datos “limpios” y datos afectados por el ruido considerado (6 corridas en total). Reportar $\hat{R}_e$ y su error respecto del valor real en cada caso. Para pensar: el orden de precisión predicho en el ítem 2 (usando solo el mapa de sensibilidad) ¿coincide con el orden obtenido empíricamente en el ítem 3? Si no coincide, ¿a qué lo atribuiría (error de optimización, elección de ΔRe , u otra causa)?
- **(Opcional) Problema paramétrico.** Reformular el modelo forward incluyendo Re como *feature* adicional de entrada, muestreando $Re \sim \mathcal{U}(50, 150)$ en cada punto de colocación durante el entrenamiento físico (sin datos rotulados). Con este modelo entrenado una única vez:
 - Calcular $\epsilon_{Re}(x, y)$ vía autograd directo (derivando la salida respecto del input Re), evaluado en $Re = 100$, y comparar contra el mapa obtenido por diferencias finitas en el primer ítem. ¿Coinciden?
 - Usando la mejor configuración de sensores del ítem anterior, identificá $\hat{R}_e$ **sin reentrenar los pesos de la red**: optimizar únicamente el valor de Re (como si fuera el único parámetro libre) para minimizar el error contra los datos rotulados. Comparar el resultado y el tiempo de cómputo contra el esquema del ítem de entrenamiento inverso (donde pesos y Re se ajustan juntos).